

כריית טקסט – תרגיל בית מספר 1

תרגיל זה מטרתו לבחון את הדרכים השונות להכין טקסט לניתוח, לתרגל שימוש בפונקציות ניקוי הקיימות ולהבין את האתגרים והנושאים אליהם יש לשים לב כאשר מבצעים ניקיון והכנה של טקסט.

סט הנתונים בו נשתמש מכיל טוויטים שסווגו לסנטימנט חיובי ושלילי. מטרתנו בעתיד תהיה לבנות מסווג שיסווג טוויטים לטוויטים חיוביים וטוויטים שליליים באמצעות ניתוח של תוכן הטקסט. בשלב זה עלינו להכין את הקובץ לניתוח. קובץ הנתונים מופיע באתר הקורס בשם Sentiment180_2000.csv, כל שורה במסד זה טוויט.

להלן תיאור משתני המסד:

שם משתנה	תיאור
Polarity	0 = שלילי 4 = חיובי
ID	מספר מזהה של הטוויט
Date	תאריך הטוויט
Query	שאלתא
User	שם משתמש שיצר את הטוויט
Text	התוכן של הטוויט

ניתן לקרוא פרטים נוספים על סט הנתונים בקישורים הבאים:

<http://help.sentiment140.com/for-students/>

<https://cs.stanford.edu/people/alecmgo/papers/TwitterDistantSupervision09.pdf>

1. טענו את סט הנתונים ל R לתוך Data frame.
2. (1 נק') צרו קורפוס המכיל את הטקסטים הנ"ל.
3. (3 נק') נקו את הטקסט בהתאם למה שנלמד בכיתה ובהתאם למטרת הניתוח. **דווחו לפלט באילו פונקציות השתמשתם לניקוי ומאיזו סיבה (צינו לפחות חמישה ניקיונות שביצעתם). ציינו אילו עוד פעולות הייתם מבצעים בעתיד כדי לנקות את הקובץ בצורה מיטבית.**
4. (3 נק') שנו את סדר הפונקציות בהן השתמשתם בסעיף הקודם כך שיווצר סדר שגוי. פרטו שני שינויים שביצעתם המראים כיצד שינוי סדר הפעולות פגע בביצוע הניקוי. הציגו כל שינוי בנפרד. בקוד יש להציג את הניקוי המקורי (בשאלה 3), ואת שתי שיטות הניקוי הנוספות. גם אם שיניתם רק שורה אחת יש להציג את כל פונקציות הניקוי כך שניתן יהיה להריץ ולראות את השינוי. **דווחו לפלט מה השינוי שביצעתם, למה הוא גרם והציגו דוגמא מהטקסט עבור כל שינוי.**
5. (1 נק') צרו מטריצת מונחים-מסמכים, Term Document Matrix (TDM), המכילה את כל המונחים לאחר ניקוי. כמה מונחים יש במטריצה? מה ה sparsity שלה? **דווחו לפלט.**

6. (1 נק') סננו מהמטריצה את כל המונחים המופיעים בשני מסמכים או פחות. מה ה sparsity כעת? **דווחו לפלט**
7. (1 נק') צרו טבלה המכילה את 20 המונחים המופיעים בתדירות הגבוהה ביותר בקורפוס אחרי ניקוי. הטבלה תכיל מונח ומספר הפעמים שהוא מופיע בטקסט. **הדפסו 6 שורות ראשונות של הטבלה ודווחו לפלט.**

אופן ההגשה :

- הגשה בזוגות או ביחידים.
- הגשה דרך אתר למידה.
- יש להגיש קובץ R מתועד, וקובץ פלט הגשה בפורמט pdf/ word המכיל את התשובות לשורות המסומנות בצהוב.
- אין לכווץ את קבצי ההגשה (zip).