

כריית טקסט – תרגיל בית מספר 2

תרגיל זה מטרתו לבצע ניתוח רגשות (sentiment analysis) מבוסס לקסיקונים תוך שימוש בספריית sentimentr ולהפיק תובנות לגבי הסיבה לסנטימנט חיובי או שלילי. סט הנתונים מכיל 1000 ביקורות על דירות בבוסטון מאתר Airbnb.

סט הנתונים מופיע באתר הקורס בקובץ bos_airbnb_1k.csv, כל שורה במסד זה ביקורת.

הביקורות מופיעות בעמודת comments.

שאלות:

1. טענו את קובץ הנתונים ל R. בצעו ניקיונות רלוונטיים.
 2. (2 נקודות) חשבו את ה sentiment של כל ביקורת באמצעות ספריית 'sentimentr'. הוסיפו עמודה בשם sentiment לסט הנתונים המקורי.
 3. (1 נקודות) עברו על ציון ה sentiment שקיבלתם. בחנו ביקורות בטווחים שונים של sentiment. מצאו שתי ביקורות בהן ציון ה sentiment אינו מדויק. **העתיקו את הביקורות והציון שקיבלתם לקובץ הפלט. נמקו למה לדעתכם הציון צריך להיות שונה.**
 4. (1 נקודות) הריצו את הביקורות מהסעיף הקודם ב ChatGPT או כלי GenAI אחר. בקשו ממנו לסווג את הביקורת לחיובית/ שלילית/ ניטרלית ולתת ציון סנטימנט. **רשמו מה ביקשתם, מה תוצאת הסיווג ומה ציון הסנטימנט.**
 5. (2 נקודות) **הוסיפו ללקסיקון** ביטוי חיובי או שלילי שלא קיים בו ולדעתכם יש להוסיפו. במידה וחיובי תנו ציון $polarity = 1$ ובמידה ושלילי תנו ציון -1. לאחר ההוספה חשבו את הסנטימנט עבור כל הביקורות תוך שימוש בלקסיקון המעודכן. הוסיפו עמודה בשם sentiment_updated לסט הנתונים המקורי ושמרו לקובץ csv בשם bos_airbnb_1k_sentiment_new.csv. חפשו שם משפטים המכילים את הביטוי שהוספתם ובדקו האם ציון הסנטימנטים שונה. **העתיקו לקובץ הפלט מספר שורות הכוללות את הטקסט הרלוונטי ושני ציוני ה sentiment (עדיף צילום מסך).**
 6. (4 נקודות) הפרידו את הביקורות לביקורות חיוביות ולביקורות שליליות וצרו comparison cloud המציג את ההבדלים בין הביקורות החיוביות לביקורות השליליות. בצעו ניקיונות רלוונטיים. **העתיקו לפלט את התרשימים וציינו חמישה מונחים בולטים בביקורות החיוביות וחמישה בביקורות השליליות.**
- שימו לב: לפני שיוצרים comparison cloud יש לאחד את כל הביקורות החיוביות למסמך אחד ואת כל הביקורות השליליות למסמך שני, ניתן להשתמש בפקודה paste לצורך כך כפי שלמדנו בכיתה.

אופן ההגשה:

- הגשה דרך אתר למידה.
- יש להגיש קובץ R מתועד, וקובץ פלט הגשה בפורמט pdf/ word המכיל את התשובות לשורות המסומנות בצהוב.
- אין לכווץ את קבצי ההגשה (zip).
- הגשה בזוגות או יחידים.