

כריית טקסט – תרגיל בית מספר 3

בתרגיל זה ניקח אוסף של טקסטים ונחלק לקבוצות (topics). נשתמש בסט הנתונים המכיל ביקורות על דירות בבוסטון שראינו בכיתה. נמצא נושאים עבור ביקורות חיוביות ועבור ביקורות שליליות.

שאלות:

1. (2 נקודות) טענו את הקובץ וחשבו את הסנטימנט בדומה לנלמד בכיתה בחלק 3. אין צורך לבצע ניקיונות לפני חישוב הסנטימנט. חלקו את הנתונים לביקורות חיוביות ($\text{sentiment} > 0$) ולביקורות שליליות ($\text{sentiment} < 0$).
2. (1 נקודות) כעת נרצה לבצע topic modeling לכל סט נתונים (ביקורות חיוביות וביקורות שליליות), בצעו ניקיונות רלוונטיים לפני ביצוע החלוקה.
3. (3 נקודות) בצעו חלוקה של הטקסטים החיוביים והשליליים לקבוצות באמצעות אלגוריתם LDA. בחרו פרמטרים ומספר קבוצות לפי השיטות שנלמדו בכיתה (ldatuning). **דווחו לקובץ הפלט אילו פרמטרים בחרתם, לכמה קבוצות חילקתם ולמה, הציגו בפלט את הגרפים של ldatuning עליהם הסתמכתם.**
4. (2 נקודות) מהם המאפיינים של כל קבוצת מסמכים? מהן המילים העיקריות המאפיינות כל קבוצה? **דווחו לקובץ הפלט את עשרת המילים המרכזיות המאפיינות כל קבוצה.**
5. (2 נקודות) צרו שתי ויזואליזציות לתאור שתי החלוקות באמצעות LDAvis. **הדביקו צילומי מסך בקובץ הפלט. האם החלוקות טובות לדעתכם?**

אופן ההגשה:

- הגשה דרך אתר למידה.
יש להגיש קובץ R מתועד (ומסודר), קובץ פלט הגשה בפורמט word/pdf המכיל את התשובות לשורות המסומנות בצהוב וקובץ נתונים בפורמט csv.
- אין לכווץ את קבצי ההגשה (zip).
- הגשה בזוגות או ביחידים.