

כריית טקסט – תרגיל בית מספר 2

תרגיל זה מטרתו לבצע ניתוח רגשות (sentiment analysis) מבוסס לקסיקונים תוך שימוש בספריית sentimentr ולהפיק תובנות לגבי הסיבה לסנטימנט חיובי או שלילי. סט הנתונים מכיל 1000 ביקורות על דירות בבוסטון מאתר Airbnb.

סט הנתונים מופיע באתר הקורס בקובץ bos_airbnb_1k.csv, כל שורה במסד זה ביקורת.

הביקורות מופיעות בעמודת comments.

שאלות:

1. טענו את קובץ הנתונים ל R. בצעו ניקיונות רלוונטיים.
 2. (2 נקודות) חשבו את ה sentiment של כל ביקורת באמצעות ספריית 'sentimentr'. הוסיפו עמודה בשם sentiment לסט הנתונים המקורי.
 3. (1 נקודות) עברו על ציון ה sentiment שקיבלתם. בחנו ביקורות בטווחים שונים של sentiment. מצאו שתי ביקורות בהן ציון ה sentiment אינו מדויק. **העתיקו את הביקורות והציון שקיבלתם לקובץ הפלט. נמקו למה לדעתכם הציון צריך להיות שונה.**
 4. (1 נקודות) הריצו את הביקורות מהסעיף הקודם ב ChatGPT או כלי GenAI אחר. בקשו ממנו לסווג את הביקורת לחיובית/ שלילית/ ניטרלית ולתת ציון סנטימנט. **רשמו מה ביקשתם, מה תוצאת הסיווג ומה ציון הסנטימנט.**
 5. (2 נקודות) **הוסיפו ללקסיקון ביטוי חיובי או שלילי שלא קיים בו ולדעתכם יש להוסיפו.** במידה וחיובי תנו ציון $polarity = 1$ ובמידה ושלילי תנו ציון -1. לאחר ההוספה חשבו את הסנטימנט עבור כל הביקורות תוך שימוש בלקסיקון המעודכן. הוסיפו עמודה בשם sentiment_updated לסט הנתונים המקורי ושמרו לקובץ csv בשם bos_airbnb_1k_sentiment_new.csv. חפשו שם משפטים המכילים את הביטוי שהוספתם ובדקו האם ציון הסנטימנטים שונה. **העתיקו לקובץ הפלט מספר שורות הכוללות את הטקסט הרלוונטי ושני ציוני ה sentiment (עדיף צילום מסך).**
 6. (4 נקודות) הפרידו את הביקורות לביקורות חיוביות ולביקורות שליליות וצרו comparison cloud המציג את ההבדלים בין הביקורות החיוביות לביקורות השליליות. בצעו ניקיונות רלוונטיים. **העתיקו לפלט את התרשימים וצינו חמישה מונחים בולטים בביקורות החיוביות וחמישה בביקורות השליליות.**
- שימו לב: לפני שיוצרים comparison cloud יש לאחד את כל הביקורות החיוביות למסמך אחד ואת כל הביקורות השליליות למסמך שני, ניתן להשתמש בפקודה paste לצורך כך כפי שלמדנו בכיתה.

אופן ההגשה:

- הגשה דרך אתר למידה.
- יש להגיש קובץ R מתועד, וקובץ פלט הגשה בפורמט pdf/ word המכיל את התשובות לשורות המסומנות בצהוב.
- אין לכווץ את קבצי ההגשה (zip).
- הגשה בזוגות או יחידים.

כריית טקסט - קובץ פלט לתרגיל מספר 2

מגישים:

- גנאדי בירפיר (ת.ז : 312741622)
- ניב קוטק (ת.ז : 208236315)

סעיף 3

דוגמא לביקורות לא מדויקות והסבר :

א. ביקורת חיובית שקיבלה ציון שלילי – קיימות מספר מילים שליליות כמו :
"couldn't" – מילה זו בדרך כלל מתארת שלילה, אך כאן היא חלק מביטוי חיובי
"just" – תלוי בהקשר, מילה זו יכולה להיות מרמזת על משהו מוגבל או מצמצם, אבל כאן היא מתארת קרבה חיובית.

Comment: The location is awesome!! Its just a couple of blocks from South Station, close to great restaurants, and bars and the .VIEW!! couldn't have picked a better location. The Boston Tea Party Museum is close too

Calculated Sentiment: 0.3 -0.02357023 -0.3265986 0

Average Sentiment: -0.01309019

ב. ביקורת חיובית שקיבלה ציון שלילי :

Quiet-למרות שההקשר כאן חיובי (שקט), ייתכן שבסיטואציות אחרות השקט ייראה כחיסרון, למשל אם מחפשים מקום תוסס.
could have spent much more days - ייתכן שמישהו יפרש את זה כחצי ביקורת על כך שהייתם מוגבלים בזמן ולא הצלחתם לנצל את השהות

Comment: We spent 5 nights in Sanjay's appartement. For the two of us it had the perfect size. We could have spent much more days there! All in all a really modern, quiet and clean apartment.

Calculated Sentiment: -0.1020621 0.2371708 -0.8980256 0.6577538

Average Sentiment: -0.0262907

:ChatGPT prompt

Please write this text like this: The location is awesome!! Its just a couple of blocks from South Station, close to great restaurants, and bars and the VIEW!! couldn't have picked a better location. The Boston Tea Party Museum is close too. Classify the sentence as positive/negative or neutral. And write the sentiment score.

תוצאה:

Rewritten Text:

The location is incredible! Just a short walk from South Station, near amazing restaurants, bars, and THE VIEW!! Absolutely perfect. Plus, the Boston Tea Party Museum is nearby too.

Classification:

Positive

Sentiment Score:

Sentiment scores typically range from -1 (very negative) to +1 (very positive). This sentence would likely score **+0.95** due to its highly enthusiastic and positive tone.

:ChatGPT prompt

Please write this text like this: We spent 5 nights in Sanjay's appartement. For the two of us it had the perfect size. We could have spent much more days there! All in all a really modern, quiet and clean apartment. Classify the sentence as positive/negative or neutral. And write the sentiment score.

תוצאה :

Rewritten Text:

We stayed for 5 nights at Sanjay's apartment. It was the perfect size for the two of us. We could have easily spent even more time there! Overall, a very modern, quiet, and clean place.

Classification:

Positive

Sentiment Score:

+0.90 — The tone is highly positive, reflecting satisfaction and enthusiasm about the experience.

גירסת הצ'אט : הגרסה הנוכחית של הצ'אט היא GPT-4

סעיף 5

מספר שורות מהקובץ כולל שני חישובי הסנטימנט (צילום מסך של המשפטים המכילים את המילה/הביטוי שהוספתם ללקסיקון):

num: 18

Comment: jose was always available. feedback and directions were great - fantastic location. local corner coffee shop for breakfast... excellent. salem street right around the corner. lots of stairs to climb, the floor - don't bring lots of luggage. bed was quite comfortable. apartment needs to be cleaner. bathroom has seen its better days, needs repairs.

Average Sentiment: 0.3849909

Average Sentiment Updated: 0.2690138

num: 19

Comment: listing accurate, clean and well kept apartment. neighborhood lively and conveniently located. owner was extremely helpful and available for questions.

Average Sentiment: 0.8181407

Average Sentiment Updated: 0.9441289

num: 20

Comment: thoroughly enjoyed our time in this wonderful house and had the pleasure of meeting robin & victoria. had never done airbnb before and the concept of letting yourself in and making yourself at home seemed a little strange to begin with, however robin kept us informed via text. the area is great for eating and exploring and has a real community spirit. transport links are also good. would definitely stay here again.

Average Sentiment: 0.3553985

Average Sentiment Updated: 0.4390213

num: 21

Comment: great apartment location and very spacious. ideal for exploring boston. only downside is its an older apartment and could be cleaner.

Average Sentiment: 0.497384

Average Sentiment Updated: 0.3466284

num: 22

Comment: the room was not shown as advertised. the room and bathroom seemed much smaller. there was no kitchen sink, one of the towels provided still smelled like mold, the shower had mold growing on the tiles and the bathroom was much smaller. the bed and comforter provided had stains on them. it resembled a college dorm room. the only good thing about our stay was that we did not have to stay in that room for more than hours. the area itself was nice. close to the train and northeastern university.

Average Sentiment: 0.04821567

Average Sentiment Updated: 0.02140263

סעיף 6

: Comparison cloud



מונחים :

5 מונחים חיוביים בולטים: great, boston, comfortable, clean, recommend:

5 מונחים שליליים בולטים: Room, Dirty, however, night, like :

```
# Using libraries
```

```
library(stringi)
```

```
library(textstem)
```

```
library(tm)
```

```
library(qdap)
```

```
library(sentimentr)
```

```
library(wordcloud)
```

```
library(ggthemes)
```

```
library(lexicon)
```

```
# set working directory
```

```
setwd("C:/Users/niv/Desktop/Text mining/EX2")
```

```
#~~~~~Q.1~~~~~
```

```
# Set Options
```

```
options(stringsAsFactors=FALSE) #don't treat strings as factors (categories)
```

```
Sys.setlocale('LC_ALL','C')
```

```
# read csv
```

```
airbnb.df<-read.csv('bos_airbnb_1k.csv')
```

```
head(airbnb.df)
```

```
#text coloum into new data frame
```

```
comments.df<-airbnb.df[, 'comments']
```

```
head(comments.df)
```

```
#Create corpus
```

```
comments.vec<- VectorSource(comments.df)
```

```
comments.cor<- VCorpus(comments.vec)
```

```
class(comments.cor)
```

```
# Cleaning test by function
```

```
check <- function(text.cor,name) {
```

```
  cat(name,"\\n\\n")
```

```
  for (i in 1: 6) {
```

```
    print(text.cor[[i]][1])
```

```
  }
```

```
  cat("\\n\\n")
```



```
}
```

```
### Text cleaning
```

```
# transferring data to lowercase
```

```
comments.cor <- tm_map(comments.cor,content_transformer(tolower))
```

```
check(comments.cor,"lowercase")
```

```
# remove numbers
```

```
comments.cor <- tm_map(comments.cor , removeNumbers)
```

```
check(comments.cor,"remove numbers")
```

```
# remove white spaces
```

```
comments.cor <- tm_map(comments.cor ,stripWhitespace)
```

```
check(comments.cor,"remove white spaces")
```

```
comments.cor <- lemmatize_words(comments.cor)
```

```
# Convert cleaned corpus to text
```

```
cleaned_comments <- unlist(lapply(comments.cor, function(x) x$content))
```

```
#~~~~~Q.2~~~~~
```

```
# Sentiment analysis
```

```
airbnb.df$sentiment <- sentiment_by(cleaned_comments,question.weight=0)$ave_sentiment
```

```
head(airbnb.df$sentiment)
```

```
table(sign(airbnb.df$sentiment))
```

```
#~~~~~Q.3~~~~~
```

```
for (i in 1:nrow(airbnb.df)) {
```

```
  # Check if the sentiment is within the specified range
```

```
  if (airbnb.df$sentiment[i] < 0 && airbnb.df$sentiment[i] > -0.1) {
```

```
    # Calculate the sentiment for the current comment
```

```
    senti <- sentiment(cleaned_comments[i],question.weight=0)$sentiment
```

```
  # Initialize positive and negative sentiment accumulators
```

```
  positive <- 0
```

```
negative <- 0
```

```
for (var in senti) {
```

```
  if (var > 0) {
```

```
    positive <- positive + var
```

```
  } else {
```

```
    negative <- negative + var
```

```
  }
```

```
}
```

```
# Check if the sum of positive and negative sentiments meets criteria
```

```
if ((positive + negative >= -0.15) && (positive != 0)) {
```

```
  # Print the 'comments' column for the current row
```

```
  cat("Comment: ", airbnb.df$comments[i], "\n")
```

```
  # Print the calculated sentiment value
```

```
  cat("Calculated Sentiment: ", senti, "\n")
```

```
# Print the average sentiment value from the data frame

cat("Average Sentiment: ", airbnb.df$sentiment[i], "\n")
```

```
# Add a blank line for better readability

cat("\n")
```

```
}
```

```
}
```

```
}
```

```
#~~~~~Q.4~~~~~
```

```
#ChatGPT:
```

```
#~~~~~Q.5~~~~~
```

```
#check if a word exists in the lexicon
```

```
lexicon::hash_sentiment_jockers_rinker["dirty "] #NA
```

```
lexicon::hash_sentiment_jockers_rinker["repair"] #NA
```

```
lexicon::hash_sentiment_jockers_rinker["be cleaner"] #NA
```

```
lexicon::hash_sentiment_jockers_rinker["kept"] #NA
```

```
lexicon::hash_sentiment_jockers_rinker["mold"] #NA
```

```
# add new words to the dictionary
```

```
library(lexicon)
```

```
updated_hash_sentiment <- sentimentr:::update_polarity_table(lexicon::hash_sentiment_jockers_rinker,
```

```
  x = data.frame(
```

```
    words = c('be cleaner', 'repairs', 'dirty', 'mold', 'kept'),
```

```
    polarity = c(-1, -1, -1, -1, 1),
```

```
    stringsAsFactors = FALSE
```

```
  )
```

```
)
```

```
airbnb.df$sentiment_updated <-  
sentiment_by(cleaned_comments,polarity_dt=updated_hash_sentiment,question.weight=0)$ave_sentiment  
  
head(airbnb.df$sentiment_updated)  
  
table(sign(airbnb.df$sentiment_updated))
```

```
# write to csv
```

```
write.csv(airbnb.df,'bos_airbnb_1k_sentiment_new.csv')
```

```
new_words <- c('be cleaner', 'repairs', 'dirty', 'mold', 'kept')
```

```
num<-1
```

```
# Loop through each row in the DataFrame
```

```
for (i in 1:nrow(airbnb.df)) {
```

```
  # Extract comments for the current row
```

```
  comments <- cleaned_comments[i]
```

```
  # Loop through each comment if it's a list or vector of comments
```

```
  for (j in 1:length(comments)) {
```

```
    # Loop through the new_words
```

```
    bool<-TRUE
```

```

for (k in 1:length(new_words)) {

  # Check if the new_word appears in the comment

  if (grepl(new_words[k], comments[j], ignore.case = TRUE)&&bool&&airbnb.df$sentiment[i] != airbnb.df$sentiment_updated[i]) {

    bool<-FALSE

    cat("num: ",num,"\n")

    num<-num+1

    cat("Comment: ", comments[j], "\n")

    cat("Average Sentiment: ", airbnb.df$sentiment[i], "\n")

    cat("Average Sentiment Updated: ", airbnb.df$sentiment_updated[i], "\n")

    cat("\n\n")

  }

}

}

}

```

#~~~~~Q.6~~~~~

#Dividing positive and negative comments

```
negative.df<-airbnb.df[airbnb.df$sentiment<0,'comments']
```

```
positive.df<-airbnb.df[airbnb.df$sentiment>0,'comments']
```

#cleaning

```
clean.vec<-function(text.vec){
```

```
  text.vec <- tolower(text.vec)
```

```
  text.vec<-removeWords(text.vec,stopwords('english'))
```

```
  text.vec <- removePunctuation(text.vec)
```

```
  text.vec <- removeNumbers(text.vec)
```

```
  text.vec <- stripWhitespace(text.vec)
```

```
}
```

```
positive.vec<-clean.vec(positive.df)
```

```
negative.vec<-clean.vec(negative.df)
```



```
#concatenate all the comments together
```

```
negative.vec<-paste(negative.vec,collapse = " ")
```

```
positive.vec<-paste(positive.vec,collapse = " ")
```

```
comparisonCloud.df<-c(positive.vec,negative.vec)
```

```
comparisonCloud.corpus<-VCorpus(VectorSource(comparisonCloud.df))
```

```
tdm<-TermDocumentMatrix(comparisonCloud.corpus)
```

```
tdm.matrix<- as.matrix(tdm)
```

```
colnames(tdm.matrix)= c("positive","negative")
```

```
comparison.cloud(tdm.matrix,max.words = 150,random.order = FALSE,title.size = 1,
```

```
  colors = brewer.pal(ncol(tdm.matrix),"Dark2"))
```