

כריית טקסט – תרגיל בית מספר 3

בתרגיל זה ניקח אוסף של טקסטים ונחלק לקבוצות (topics). נשתמש בסט הנתונים המכיל ביקורות על דירות בבוסטון שראינו בכיתה. נמצא נושאים עבור ביקורות חיוביות ועבור ביקורות שליליות.

שאלות:

1. (2 נקודות) טענו את הקובץ וחשבו את הסנטימנט בדומה לנלמד בכיתה בחלק 3. אין צורך לבצע ניקיונות לפני חישוב הסנטימנט. חלקו את הנתונים לביקורות חיוביות ($\text{sentiment} > 0$) ולביקורות שליליות ($\text{sentiment} < 0$).
2. (1 נקודות) כעת נרצה לבצע topic modeling לכל סט נתונים (ביקורות חיוביות וביקורות שליליות), בצעו ניקיונות רלוונטיים לפני ביצוע החלוקה.
3. (3 נקודות) בצעו חלוקה של הטקסטים החיוביים והשליליים לקבוצות באמצעות אלגוריתם LDA. בחרו פרמטרים ומספר קבוצות לפי השיטות שנלמדו בכיתה (ldatuning). **דווחו לקובץ הפלט אילו פרמטרים בחרתם, לכמה קבוצות חילקתם ולמה, הציגו בפלט את הגרפים של ldatuning עליהם הסתמכתם.**
4. (2 נקודות) מהם המאפיינים של כל קבוצת מסמכים? מהן המילים העיקריות המאפיינות כל קבוצה? **דווחו לקובץ הפלט את עשרת המילים המרכזיות המאפיינות כל קבוצה.**
5. (2 נקודות) צרו שתי ויזואליזציות לתאור שתי החלוקות באמצעות LDAvis. **הדביקו צילומי מסך בקובץ הפלט. האם החלוקות טובות לדעתכם?**

אופן ההגשה:

- הגשה דרך אתר למידה.
יש להגיש קובץ R מתועד (ומסודר), קובץ פלט הגשה בפורמט word/pdf המכיל את התשובות לשורות המסומנות בצהוב וקובץ נתונים בפורמט csv.
- אין לכווץ את קבצי ההגשה (zip).
- הגשה בזוגות או ביחידים.

בקובץ פלט לתרגיל מספר 3

שאלה 3

ביקורות חיוביות:

פרמטרים :


- seed=10 - נקבע את הסיד כדי לקבל חלוקה עקבית שווה
- alpha=0.1 - נקבע את האלפא כמספר קטן בשביל במסמך מסוים ישתייך לנושא מסוים ולא להרבה נושאים. כלומר בחירה באלפא 0.1 על מנת שבסבירות גבוהה האלגוריתם ישייך לטופיק מסוים.
- "method" = "Gibbs" - נבחר את שיטת החלוקה ל GIBBS

מספר קבוצות :

ננסה לבצע חלוקה של 4, 8, 9

$K=8$ - נראה כי חלוקה ל-8 אשכולות מייצרת נקודות קיצון (מיני/מקס) במספר אלגוריתמים ולכן זה מחזק את הבחירה במספר זה.

גרף תומך החלטה :



ביקורות שליליות:

פרמטרים :


- seed=10 - נקבע את הסיד כדי לקבל חלוקה עקבית שווה
- alpha=0.1 - נקבע את האלפא כמספר קטן בשביל במסמך מסוים ישתייך לנושא מסוים ולא להרבה נושאים. כלומר בחירה באלפא 0.1 על מנת שבסבירות גבוהה האלגוריתם ישייך לטופיק מסוים.
- "method" = "Gibbs" - נבחר את שיטת החלוקה ל GIBBS

מספר קבוצות :

ננסה לבצע מספר חלוקות של 3, 5, 7

$K=5$ - נראה כי חלוקה ל-5 אשכולות מייצרת נקודות קיצון (מיני/מקס) במספר אלגוריתמים ולכן זה מחזק את הבחירה במספר זה

גרף תומך החלטה:



שאלה 4

ביקורות חיוביות:

עשרת המילים המרכזיות בכל קבוצה:

```
> termsByTopic_positive
      Topic 1 Topic 2 Topic 3 Topic 4 Topic 5 Topic 6 Topic 7 Topic 8
[1,] "home"  "arriv" "room"  "stay" "great" "walk"  "apart" "apt"
[2,] "area"  "leav"  "good"  "boston" "locat" "boston" "get"  "jamaica"
[3,] "much"  "get"   "bed"   "hous"  "stay"  "stay"  "good"  "sara"
[4,] "trip"  "room"  "nice"  "make"  "place" "place"  "stay"  "plain"
[5,] "space" "late"  "clean" "host"  "apart" "good"  "night" "part"
[6,] "feel"  "time"  "bathroom" "great" "recommend" "great" "peopl" "ray"
[7,] "full"  "give"  "stay"  "home"  "boston" "apart" "door"  "suppli"
[8,] "long"  "find"  "realli" "good"  "host"  "locat" "great" "clean"
[9,] "access" "day"  "comfort" "feel"  "clean" "nice"  "air"  "jim"
[10,] "like"  "meet" "need"  "place" "comfort" "also"  "one"  "paul"
> |
```

1. Living Experience and Accessibility :
home area much trip space feel full long access like
2. Availability and Timing :
arriv leav get room late time give find day meet
3. Comfort and Quality of Stay :
room good bed nice clean bathroom stay realli comfort need
4. Experiences and Hosting in Boston :
stay boston hous make host great home good feel place
5. Location and Recommended Hosting :
great locat stay place apart recommend boston host clean comfort
6. Positive Atmosphere Stay :
walk boston stay place good great apart locat nice also
7. Service and Social Interactions :
apart get good stay night peopl door great air one
8. Apartments and Clean Environment :
apt jamaica sara plain part ray suppli clean jim paul

ביקורות שליליות:

עשרת המילים המרכזיות בכל קבוצה :

> termsByTopic_negative

	Topic 1	Topic 2	Topic 3	Topic 4	Topic 5
[1,]	"room"	"locat"	"door"	"place"	"arriv"
[2,]	"apart"	"boston"	"terribl"	"leav"	"find"
[3,]	"clean"	"take"	"email"	"good"	"dirti"
[4,]	"nice"	"great"	"recent"	"like"	"stay"
[5,]	"quit"	"park"	"robert"	"night"	"can"
[6,]	"bathroom"	"close"	"also"	"stay"	"extrem"
[7,]	"back"	"just"	"casa"	"bed"	"also"
[8,]	"friend"	"never"	"con"	"host"	"feel"
[9,]	"just"	"receiv"	"entir"	"pay"	"idea"
[10,]	"much"	"avail"	"home"	"time"	"inform"


> |

1. Room and Accommodation Quality :
room apart clean nice quit bathroom back friend just much
2. Location and Accessibility :
locat boston take great park close just never receiv avail
3. Negative Experiences and Complaints :
door terribl email recent robert also casa con entir home
4. General Stay and Host Feedback :
place leav good like night stay bed host pay time
5. Arrival and Communication Issues :
arriv find dirti stay can extrem also feel idea inform

שאלה 5

צילומי מסך של שתי הויזואליזציות :

ביקורות חיוביות:




ביניהם, אך קיימים שלושה טופיקים שבהם יש חפיפה מסוימת. למרות זאת, החלוקה של שאר הטופיקים מצוינת ומעידה על חלוקה מרשימה

ביקורת שלילית:


Selected Topic:

Intertopic Distance Map (via multidimensional scaling)



Slide to adjust relevance metric:⁽²⁾ $\lambda = 1$

Top-30 Most Salient Terms¹



1. saliency(term w) = frequency(w) * [sum_t p(t | w) * log(p(t | w)/p(t)) for topics t; see Chuang et. al (2012)
 2. relevance(term w | topic t) = $\lambda * p(w | t) + (1 - \lambda) * p(w | t)/p(w)$; see Sievert & Shirley (2014)

האם החלוקות טובות לדעתכם – ביקורת שלילית:

החלוקה של הטופיקים מראה תוצאות מרשימות, עם הפרדה ברורה. המרחקים המשמעותיים בין הטופיקים והעובדה שאף אחד אינו חופף או עולה על נושא אחר מעידים על חלוקה מעולה

```

# Using libraries

library(stringi)

library(textstem)

library(tm)

library(qdap)

library(sentimentr)

library(wordcloud)

library(ggthemes)

library(lexicon)

library(topicmodels)

# set working directory

setwd("C:/Users/niv/Desktop/Text mining/EX3")

#~~~~~Q.1~~~~~

# Set Options

options(stringsAsFactors=FALSE) #don't treat strings as factors (categories)

Sys.setlocale('LC_ALL','C')

# read csv

airbnb.df<-read.csv('bos_airbnb_1k.csv')

head(airbnb.df)

#text coloum into new data frame

comments.df<-airbnb.df[, 'comments']

head(comments.df)

# Sentiment analysis

airbnb.df$sentiment <- sentiment_by(comments.df,question.weight=0)$save_sentiment

head(airbnb.df$sentiment)

```

```
table(sign(airbnb.df$sentiment))
```

```
#Dividing positive and negative comments
```

```
negative.df<-airbnb.df[airbnb.df$sentiment<0,'comments']
```

```
positive.df<-airbnb.df[airbnb.df$sentiment>0,'comments']
```

```
#~~~~~Q.2~~~~~
```

```
#clean.data function
```

```
negative.df<- gsub("\n", " ",negative.df)
```

```
positive.df<-gsub("\n", " ",positive.df)
```

```
negative.df<- textclean::replace_non_ascii(negative.df,replacement = "")
```

```
positive.df<- textclean::replace_non_ascii(positive.df,replacement = "")
```

```
clean.data <- function(text){
```

```
  myCorpus <- VCorpus(VectorSource(text))
```

```
  myCorpus <- tm_map(myCorpus, content_transformer(tolower))# convert to lower case
```

```
  myCorpus <- tm_map(myCorpus, removeWords, stopwords("english")) #remove stopwords
```

```
  myCorpus <- tm_map(myCorpus, removeNumbers)# remove numbers
```

```
  myCorpus <- tm_map(myCorpus, removePunctuation)# remove punctuation
```

```
  myCorpus <- tm_map(myCorpus, stripWhitespace)# remove extra whitespace
```

```
  myCorpus <- tm_map(myCorpus, content_transformer(lemmatize_strings))
```

```
  myCorpus <- tm_map(myCorpus, stemDocument)
```

```
  return(myCorpus)
```

```
}
```

```
positive.Corpus<-clean.data(positive.df)
```



```
negative.Corpus<-clean.data(negative.df)
```

```
#~~~~~Q.3~~~~~
```

```
dtm_positive <- DocumentTermMatrix(positive.Corpus)
```

```
dtm_negative <- DocumentTermMatrix(negative.Corpus)
```

```
# Choose number of topics
```

```
library(ldatuning)
```

```
# positive
```

```
result_positive <- FindTopicsNumber(  
  dtm_positive,  
  topics = seq(from = 1, to = 10, by = 1),  
  metrics = c("Griffiths2004", "CaoJuan2009", "Arun2010", "Deveaud2014"),  
  method = "Gibbs", #VEM/Gibbs  
  control = list(seed = 10,alpha=0.1),  
  mc.cores = 2L,  
  verbose = TRUE  
)
```

```
FindTopicsNumber_plot(result_positive)
```

```
# negative
```

```
result_negative <- FindTopicsNumber(  
  dtm_negative,  
  topics = seq(from = 1, to = 10, by = 1),  
  metrics = c("Griffiths2004", "CaoJuan2009", "Arun2010", "Deveaud2014"),  
  method = "Gibbs", #VEM/Gibbs  
  control = list(seed = 10,alpha=0.1),
```

```
mc.cores = 2L,  
verbose = TRUE  
)  
FindTopicsNumber_plot(result_negative)
```

```
##run LDA with 8 topics (positive)
```

```
lda_positive <- LDA(dtm_positive, k = 8, control=list(seed=10,alpha=0.1),method = "Gibbs") #lower  
alpha, we assume documents contain fewer topics
```

```
termsByTopic_positive <- terms(lda_positive, 10)
```

```
termsByTopic_positive
```

```
##run LDA with 5 topics (negative)
```

```
lda_negative <- LDA(dtm_negative, k = 5, control=list(seed=10,alpha=0.1),method = "Gibbs") #lower  
alpha, we assume documents contain fewer topics
```

```
termsByTopic_negative <- terms(lda_negative, 10)
```

```
termsByTopic_negative
```

```
topics_positive <- topics(lda_positive)
```

```
topics_positive #assignment of term to a topic
```

```
table(topics_positive) #number of terms in each topic
```

```
topics_negative <- topics(lda_negative)
```

```
topics_negative #assignment of term to a topic
```

```
table(topics_negative) #number of terms in each topic
```

```
#~~~~~Q.4~~~~~
```

```
# The most common words in each group
```

```
# positive
```

```
# Define custom titles for each topic
```

```
topic_titles <- c(  
  "1. Living Experience and Accessibility",  
  "2. Availability and Timing",  
  "3. Comfort and Quality of Stay",  
  "4. Experiences and Hosting in Boston",  
  "5. Location and Recommended Hosting",  
  "6. Positive Atmosphere Stay",  
  "7. Service and Social Interactions",  
  "8. Apartments and Clean Environment"  
)
```

```
# Print topic titles with terms
```

```
for (i in 1:ncol(termsByTopic_positive)) {  
  cat(topic_titles[i], ":\n", termsByTopic_positive[, i], "\n\n")  
}
```

```
# negative
```

```
# Define custom titles for each topic
```

```
topic_titles <- c(  
  "1. Room and Accommodation Quality",  
  "2. Location and Accessibility",  
  "3. Negative Experiences and Complaints",  
  "4. General Stay and Host Feedback",  
  "5. Arrival and Communication Issues"  
)
```

```
# Print topic titles with terms
```

```

for (i in 1:ncol(termsByTopic_negative)) {
  cat(topic_titles[i], ":\n", termsByTopic_negative[, i], "\n\n")
}

#~~~~~Q.5~~~~~

# interactive visualization

library(LDAvis)

library(servr)

# Convert the output of a topicmodels Latent Dirichlet Allocation to JSON
# for use with LDAvis

topicmodels2LDAvis <- function(x, ...){
  post <- topicmodels::posterior(x)
  if (ncol(post[["topics"]]) < 3) stop("The model must contain > 2 topics")
  mat <- x@wordassignments
  LDAvis::createJSON(
    phi = post[["terms"]],
    theta = post[["topics"]],
    vocab = colnames(post[["terms"]]),
    doc.length = slam::row_sums(mat, na.rm = TRUE),
    term.frequency = slam::col_sums(mat, na.rm = TRUE)
  )
}

# Apply the function

#positive
Jason_positive <- topicmodels2LDAvis(lda_positive)
servis(Jason_positive)

#negative
Jason_negative <- topicmodels2LDAvis(lda_negative)
servis(Jason_negative)

```